

Singularidades en las Curvas Poblacionales en el AMBA 1991-2022

Fernando Meseri

28 de marzo de 2024

Fernando Meseri

1. Introducción

La información estadística que brindan las proyecciones de población es un insumo principal en la implementación de políticas estatales. Las proyecciones poblaciones es común encontrarlas a nivel País o Provincia, pero resulta particularmente importante poder contar con dichas proyecciones con un mayor nivel de desagregación, municipio/departamento. En este caso se analiza en particular los municipios del AMBA, Argentina para el período 1991-2022. Las proyecciones del Instituto Nacional de estadísticas y Censos (INDEC) han estimado la población dichos municipios. El valor arrojado para el CENSO 2022 en el caso de La Matanza presenta una desviación importante respecto al error promedio encontrado entre las proyecciones y el valor relevando en el CENSO 2022. A partir del análisis de datos censales y variables indirectas se analiza las curvas poblacionales, el error en las proyecciones INDEC respecto a lo arrojado en el CENSO 2022 así como el caso puntual de La Matanza.

2. Revisión bibliográfica

2.1. Marco Conceptual

La información estadística que brindan las proyecciones de población constituye una herramienta fundamental para la planificación de políticas públicas de corto, mediano y largo plazo. Permite estimar demanda potencial de bienes y servicios en distintas áreas como Salud, Educación, entre otras - Instituto Nacional de Estadísticas y Censos (INDEC,2013) [1]. El estado puede de esta forma determinar los recursos presupuestarios necesarios para satisfacer estas demandas. En la provincia de Buenos Aires ciertos aspectos del presupuesto son asignados en base a la población de cada municipio. Es necesario entonces contar con la información en un alto nivel de desagregación espacial(municipios).

2.2. Marco Teórico

La elaboración de proyecciones de población es una tarea compleja que debe ser realizada a través de un análisis exhaustivo que permita considerar los censos anteriores como también registros vitales y estimaciones de migración. (INDEC,2013) [1]. En general se ha utilizado en método de las componentes para elaborar dichas proyecciones. Mas esta metodología no ha podido ser replicada al nivel de las jurisdicciones más elementales, departamentos, por cuanto la información no es suficientemente confiable y la inestabilidad de la migración interna no admite formulación de hipótesis a mediano plazo. (Álvarez,2001) [2]. Una forma de realizar estas predicciones ha sido mediante métodos matemáticos de extrapolación en base a la información censal previa. (Álvarez,2001) [2]. El INDEC provee proyecciones de población por departamento para el período 2010-2025(INDEC, 2015) [3], particularmente para todos los municipios del AMBA. Se destaca que el crecimiento de la población en Argentina observado entre 2001 y 2010 a nivel departamental pone en evidencia las diferencias geográficas que existen en la dinámica poblaciones, con un comportamiento heterogéneo.

2.3. Estado del arte

Históricamente se observa conceso en la utilización del Método de las Componentes para la determinación de proyecciones poblacionales a nivel País o Provincia. El mismo contempla el crecimiento poblacional intercensal y proyecta cada una de las variables determinantes de forma independiente -fecundidad, mortalidad y migración (Álvarez,2001) [2]. Ciertamente la Serie de Análisis Demográfico de INDEC utiliza este método para la proyecciones Nacionales y Provinciales (INDEC, 2015) [3]. Asimismo, para población de países desarrollados, también se ha utilizado el modelo

de regresión logística en este tipo de predicciones (Gupta, Bhattacharya,Chattyopadhyay ,2012) [4]. Pero este modelo tiene ciertas limitaciones cuando se aplica a data censal dispersa en el tiempo, especialmente para países en desarrollo. Generalmente en estos casos las tasas de crecimiento relativo presentan tendencias inusuales, distintas a la tendencia decreciente de la regresión logística. Gupta et al., (2012) proponen modelos simplificados y variantes de Tsoularis and Wallace Model (TWM) que han proporcionado mejores resultados. A mayor nivel de desagregación se trabaja con métodos alternativos, como puede ser extrapolación matemática, Ratio- Correlation Method, Housing Unit Method, entre otros (Hoque, 2012)[5]. Por otra parte el centro Latinoamericano y Caribeño de Demografía (CELADE) ha promovido la utilización de otras técnicas para mejorar las estimaciones poblaciones derivadas de la extrapolación matemática. Se utiliza la metodología de variables sintomáticas, que permite establecer correlaciones a las tendencias poblacionales con información de variables indirectamente asociadas al fenómeno de crecimiento poblacional, a saber: nacimientos y defunciones, matrícula escolar, permisos de construcción, otros (Álvarez,2001)[2]. En lo que respecta a técnicas propias de ciencias de datos para análisis de información censal, se desatacan los siguientes usos: la utilización de data mining para búsqueda de patrones en la información censal, predicciones y forecasting utilizando modelos ARIMA e inducción con árboles de decisión (Chawda, Rane, Giri, 2018) [6]. También se destaca el uso de árboles regresión y clasificación para el agrupamiento o clustering en distintas clases, tomando como input información censal.

3. Definición del problema

El municipio de La Matanza una singularidad en su curva de crecimiento poblacional, tanto número de habitantes como tasas intercensales, respecto a los municipios aledaños del AMBA para el período 1991-2022.-

4. Justificación del estudio

La información estadística que brindan las proyecciones de población constituye una herramienta fundamental para la planificación de políticas públicas de corto, mediano y largo plazo. Permite estimar demanda potencial de bienes y servicios en distintas áreas como Salud, Educación, entre otras - Instituto Nacional de Estadísticas y Censos (INDEC,2013) [1]. Las proyecciones del INDEC en la serie demográfica N °38(INDEC, 2015) [3] han estimado la población para los municipios del AMBA. El valor arrojado para el censo 2022 en el caso de La Matanza presenta una desviación importante respecto al error promedio encontrado para el resto de los municipios. Es por esto que se pretende analizar la singularidad en la curva poblacional de La Matanza.

5. Alcances del trabajo y limitaciones

El alcance del trabajo es básicamente el análisis y estudio de datos censales. Comprende principalmente la utilización de datos censales del AMBA para el período 1991-2022. Analizar las curvas poblacionales, su comparación y el error en las proyecciones INDEC respecto a lo arrojado en el CENSO 2022 (INDEC ,2022) [7]. El trabajo se limita a demostrar la singularidad o no en el dato poblacional de la Matanza, sin intentar explicar las causas del hecho, particularmente en lo que se refiere al fenómeno demográfico que pudiese estar detrás de esta singularidad.

6. Hipótesis

Es posible demostrar la curva de crecimiento poblacional de la Matanza presenta una singularidad respecto a los municipios aledaños (AMBA) en situaciones socio-demográficas similares para el período 1991-2022.

Preguntas

1. ¿Se puede estimar una tasa de crecimiento promedio de la población urbana/suburbana en base a los 4 Censos anteriores?
2. ¿Se puede individualizar tasas de crecimiento distintas por municipio??
3. ¿Considerando las curvas de crecimiento reales de los municipios y las proyecciones realizadas, dado un intervalo de confianza se puede realmente afirmar que la Matanza presenta una singularidad?
4. ¿Es esperable que municipios aledaños crezcan poblacionalmente en el mismo orden de magnitud?

5. La apertura de los datos por edad, sexo y nivel de habitantes en el hogar muestra cierto comportamiento esperable, algún patrón. Se asemeja a los valores encontrado para La Matanza para Censo 2022.-

Respuestas

1. Sí, es posible determinar la tasa de crecimiento en función a los censos anteriores, utilizando estadística descriptiva.
2. Sí, es posible, ya que el censo incluye la desagregación por departamento/municipio. Luego estos se pueden agrupar en sectores de interés, ej. AMBA.
3. Si, en principio. Las causas de este fenómeno no son de interés del presente trabajo. El fenómeno demográfico es complejo, multicausal. Aun así, se pueden establecer valores de referencia acordes a la región, donde las características socio-demográficas son similar (conurbano).
4. Sí, municipios urbanos suburbanos con iguales características socio-demográficas es esperable que tengan tasas de crecimiento similares.
5. Es esperable que estos factores socio-demográficos en grandes muestras muestren patronales similares, o valores semejantes.

7. Objetivos

El objetivo del presente trabajo consiste en demostrar que la tasa de crecimiento y curva poblacional de la Matanza desde 1991 hasta 2022 presenta una singularidad respecto a aquella desarrollada por los otros municipios de conurbano bonaerense. Tomando como base los datos obtenidos en los 4 últimos censos nacionales 1991-2001-2010 y 2022.

OBJETIVOS ESPECÍFICOS

1. Procesar y unificar la información censal desde 1991 a 2022 para distintos niveles de granularidad, ya que en algunos casos no se presentan todas las variables. Se requiere un pre procesamiento y limpieza de datos importante.
2. Exploratory Data Analysis. Construir las curvas poblaciones y comparaciones geográficas de las mismas. Analizar Data mining patterns.
3. Realizar proyecciones para población censo 2022 con metodologías tradicionales modernas utilizando las variables en forma individual o combinadas, tomando como base los 3 censos anteriores (1991-2001-2010).
4. Utilizar data mining para llenar los tiempos intercensales de las variables de interés.
5. Realizar proyecciones para el censo 2022 mediante data mining (ARIMA, decision tree regression algoritm, others), utilizando los 3 censos anteriores (1991-2001-2010)
6. Comparar las curvas censales y su ajuste con las proyecciones realizadas para 2022.-
7. Determinar el error de las distintas proyecciones para 2022 para todos los municipios, comparar con la situación de la Matanza.
8. Inferir si existe alguna metodología que ajuste mejor las proyecciones para el caso del AMBA.

Variables Se trata de una hipótesis multivariable donde las variables podrían tener una relación causa-efecto sobre el fenómeno analizado.

1. **Población Total.** Variable Dependiente. Cuantitativa. Cantidad de personas que habitan un determinado sector del territorio, en distintos niveles de agregación. INDEC
2. **Tasa de Natalidad.** Independiente. Cuantitativa. Refiere a la relación que existe entre el número de nacimientos ocurridos en un cierto periodo y la cantidad total de población existente en el área geográfica.
3. **Tasa de mortalidad.** Independiente. Cuantitativa. Es la proporción de personas que fallecen respecto al total de la población en un período de tiempo, usualmente expresada en tanto por mil (%) por año.

4. **Sexo.** Contextual. Categórica. Sexo de las personas, por nivel de desagregación. INDEC
5. **Edad.** Contextual. Cuantitativa. Edad de las personas, por nivel de desagregación. INDEC
6. **Nivel educativo.** Contextual. Categórica Ordinal. Se refiere al nivel de educación máximo alcanzado por un personal hasta el momento. Primario, secundario, terciario, Universitario. INDEC
7. **Cantidad de habitantes en el hogar.** Contextual. Cuantitativa. Se determina como la cantidad de personas conviviendo de forma permanente bajo el mismo techo. INDEC
8. **Asistencia escolar.** Contextual. Categórica Ordinal. Refiere a la asistencia o no a establecimientos educativos, desagregados por edad.

8. Metodologías

8.1. Técnicas

Para dominio del problema, particularmente debido al nivel de desagregación analizado-departamentos- se utilizarán las siguientes metodologías en el trabajo.

Metodologías Tradicionales

Metodología de variables sintomáticas (distribución por prorratoe; dist. Proporcional; método de tasas variables, correlación de razones, correlación de diferencias, correlación de tasas) (Álvarez,2001) [2].

El método más sencillo es la **distribución por prorratoe**, que se basa en el supuesto de que la distribución de la población en un área mayor se distribuya entre sus áreas menores en forma idéntica a la distribución de una variable sintomática. La población del área menor i en el momento t+n está expresada por:

$$P_{(i,t+n)} = \frac{S_{(i,t+n)}}{S_{(t+n)}} \times P_{(t+n)} \quad (1)$$

Donde:

t+n es el momento n años posteriores al último censo (momento t)

P (i,t+n) población del área menor i en el momento t+n;

P (t+n) estimación disponible de la población del área mayor en el momento t+n;

S (i, t+n) valor de la variable sintomática del área menor i en el momento t+n;

S (t+n) valor de la variable sintomática del área mayor en el momento t+n.

El método de **distribución proporcional** supone que la población varía durante un período en la misma proporción que lo hace la variable sintomática en el mismo período. La población del área menor i en el momento t+n se deduce de esta relación contemplando un factor de ajuste (Fa) para que la suma de las áreas menores coincida con el área mayor:

$$P_{(i,t+n)} = \frac{S_{(i,t+n)}}{S_{(i,t)}} \times P_{(i,t)} \times F_{(a)} \quad (2)$$

$$F_{(a)} = \frac{P_{(i,t+n)}}{\frac{S_{(i,t+n)}}{S_{(i,t)}} \times P_{(i,t)}} \quad (3)$$

Donde:

t es el momento del último censo;

t+n es el momento n años posterior al último censo;

P (i,t+n) población del área menor i en el momento t+n;

P (i,t) población del área menor i en el momento t ;

S (i,t) valor de la variable sintomática del área menor i en el momento t ;

S (i,t+n) valor de la variable sintomática del área menor i en el momento t+n;

F a factor de ajuste entre suma de áreas menores estimadas y área mayor.

El método de las **tasas vitales de Bogue** consiste en estimar la población de áreas menores utilizando solamente datos de los registros vitales. Bogue (1950) tomó como supuesto la existencia de una relación inversa entre las variaciones anuales de las tasas de natalidad y de mortalidad de las áreas menores y que el desvío de las tasas propias en relación a las tasas del área mayor permanece constante a través del tiempo. La expresión del modelo es:

$$P_{(i,t+n)} = a \times \frac{B_{(i,t+n)}}{b_{(i,t+n)}} + (1 - a) \times \frac{D_{(i,t+n)}}{d_{(i,t+n)}} \quad (4)$$

Donde:

a es el coeficiente de ponderación entre las dos estimaciones;

b $(i,t+n) = [(B(i,t) / P(i,t)) / (B(\bullet,t) / P(\bullet,t))] * (B(\bullet,t+n) / P(\bullet,t+n))$

d $(i,t+n) = [(D(i,t) / P(i,t)) / (D(\bullet,t) / P(\bullet,t))] * (D(\bullet,t+n) / P(\bullet,t+n))$

B es la cantidad de nacidos vivos;

b es la tasa bruta de natalidad;

D es la cantidad de defunciones;

d es la tasa bruta de mortalidad.

EN DESARROLLO

Metodologías Data Mining CART, ARIMA, decision tree regression and classification algorithms (Chawda, Rane, Giri, 2018) [6].

8.2. Herramientas

Como herramientas se contemplan los lenguajes Python y SQL. Los datos se trabajarán en base de datos POSTGRES, para visualización geográfica se utilizará QGIS y OpenJump. En cuanto al scripting se gestionará mediante Jupyter Notebooks.

9. Referencias bibliográficas

1. Instituto Nacional de Estadística y Censos - INDEC. (2013). Proyecciones provinciales de población por sexo y grupo de edad 2010-2014. - Instituto Nacional de Estadística y Censos - INDEC, 2013. E-Book. (Vol. 1a ed.).
2. Instituto Nacional de Estadística y Censos - INDEC. (2015). Estimaciones de población por sexo, departamento y año calendario 2010-2025. (1a. ed.).
3. Gupta, Arindam , Gupta, Arindam , Gupta, Arindam (2012).Exploring New Models for Population Prediction in Detecting Demographic Phase Change for Sparse Census Data
4. Hoque, Nazrul(2012). Evaluation of small area population estimates produced by Housing Unit, Ratio-correlation, and Component Method II compared to 2000 Census counts. Canadian Studies in Population 39, No. 1-2, pg. 91-108.
5. Chawda, Manan, Rane, Rutuja, Giri, Skrinanth(2018) 2nd International Conference on Inventive Communication and Computational Technologies (ICICCT) .Demographic Progress Analysis of Census Data Using Data Mining , pg 1894-1897

10. DESARROLLO

11. Obtención de datos fuente. Consolidación Dataset

En primera instancia se busca recopilar los datos de los CENSOS poblacionales correspondientes desde 1991 elaborados por el INDEC(Instituto Nacional de Estadísticas y Censos, Argentina). Se obtuvieron desde los repositorios web del INDEC los datos correspondientes a los censos de 1991, 2001, 2010 y 2022 [1][2]. En general el INDEC dispone

la información en formatos CSV o bien archivos Microsoft Excel de difícil procesado para su ingestión por parte de un proceso de ETL.

En primera instancia los archivos no cuentan con estructura de encabezados en la primera línea, espacios en blanco, además de que presentan descripciones y comentarios en las primeras líneas. En general no respetan formatos uniformes según la dimensión de análisis (Población por Sexo, población por edad , etc) de los datos dentro del mismo periodo censal. Por otra parte, el formato de presentación de los archivos ".csv."sí como las variables relevadas se han visto modificadas desde el censo 1991 hasta el 2022. Por ejemplo el censo 1991 no relevó la cantidad de habitantes en viviendo colectivas y particulares.

Una vez analizada las variables comunes a todos estos censos, fue necesario un pre-proceso manual de los archivos para lograr uniformidad y consistencia de forma de que sean tomados por el proceso de ETL . Se removieron espacios en blanco y comentarios en la parte superior, eliminaron columnas a la izquierda.Luego fue necesario unificar y adaptar todos los archivos a la misma cantidad y nomenclatura de columnas. Siempre buscando lograr un archivo ".csv" con la estructura de "Headers" seguido de los datos,sin espacios en blanco.

Es importante aclarar que existe una base consolidada -REDATAM [9]- con toda la información censal para los censos 2001 y 2010, la misma lamentablemente no está disponible para los censos de 1991 y 2022. REDATAM [9] es un software para procesamiento estadístico especializado en microdatos de censos de población y vivienda, encuestas y estadísticas vitales, desarrollado por el CELADE - División de Población de la CEPAL, de las Naciones Unidas. Durante la fase de investigación de fuentes se analizó y manipuló este software sin resultados alentadores. Esta base sólo puede accederse mediante este software específico , no disponiendo de back ups accesibles y en general las salidas de las consultas manuales por interfase de usuario son también archivos CSV no normalizados. que requieren post-proceso.

Finalmente las variables censales definidas ,comunes al período 1991-2022,se indican en el cuadro 1.

Cuadro 1: Descripción de Variables

Variable	Description
Censo	Año del censo indicado como entero de 4 dígitos.
CodigoDepto	Código de 4 dígitos con el INDEC indica los municipios / departamentos censales.
Población	Cantidad de personas que habitan un determinado sector del territorio, en distintos niveles de agregación.
Varones	Cantidad de personas de sexo Masculino.
Mujeres	Cantidad de personas de sexo Femenino.
VivPartTot	Cantidad de viviendas particulares totales para ese nivel de agregación.
VivColectTot	Cantidad de viviendas Colectivas totales para ese nivel de agregación.
IndMasc	Índice de masculinidad.
Superficie	Superficie total del partido a la fecha del censo.

11.1. Dimensión Departamento- Slowly Changing Dimension

Al analizar los distintos censos desde 1991 hasta 2022 los departamentos del AMBA han modificado su división político – administrativa. Es decir, se han creado partidos nuevos,en otros casos partidos han cedido superficie, o bien se han fusionado otros. Esto general que la dimensión departamento cambia a través de los distintos censos.

Se analiza el enfoque **Slowly Changing Dimensions** para bases de datos. En general se trata de impactar cambios en las dimensiones del modelo , ya sea esquema estrella o copo de nieve. Este concepto fue introducido por Kimball(1996)[**12], el mismo se refiere a casos donde las dimensiones sufren pequeñas modificaciones que afectan el modelo lógico del almacén de datos.

El caso de Slowly Changing Dimensions **TIPO 1** corresponde a cambios esperádicos, no permanentes, que implican una modificación en algun atributo de la dimension. En definitiva es una corrección de este atributo, se ejecuta mediante UPDATE de las filas involucradas sin conservar el valor anterior del atributo. La instancia de Slowly Changing Dimension **TIPO 2** esta basada en la teoría de datos temporales, donde para la versión que es afectada se produce un versionao. Es decir, se inserta una nueva tupla cada vez que se produce un cambio. Se extiende la dimension generalmente con columnas "FROM" "TO" que indican fechas de validez para los atributos correspondientes a ese valor de

la dimensión. Obviamente esto afecta las consultas y todos los procesos de ETL involucrados en el almacén de datos. Por último se habla de Slowly Changing Dimension **TIPO 3** cuando si bien se desea mantener el cambio y relevar el mismo sin sobrescribir la tupla, no se mantiene el historial de la dimensión. En este caso sólo se almacena el estados actual y pasado de la misma. Simplemente se agrega una columna por cada atributo sujeto a cambios.

Es por esto que utiiza en este caso para la dimensión Departamento enfoque **SCD tipo 3**. Donde se impacta el cambio de departamento, conservando en el registro el valor anterior, de que departamento proviene y la superficie correspondiente asociada. Esto es necesario para poder luego procesar información consistente en cuento a la granularidad utilizada. Esto resulta particularmente importante para analizar las superficies de los departamentos.

En lo que respecta a las variables poblacionales se han reclasificado los datos de 1991 para corresponder con la división político-administrativa de año 2001. El INDEC consigna :"Nota: con el fin de posibilitar la comparación entre los Censos 1991 y 2001, los datos que corresponden al año 1991 fueron reprocesados según la división político - administrativa vigente al año 2001." [8] INDEC, 2001

En el cuadro 2 puede verse la dimensión departamento con los campos agregados y los comentarios correspondientes en cada caso.

11.2. Proyecciones INDEC 2010-2025

Se incorpora también al conjunto de datos que se analizarán proyecciones realizadas por el INDEC [3] que indican la "Población estimada al 1 de julio de cada año calendario por sexo, según partido. Provincia de Buenos Aires. Años 2010-2025". Las mismas se utilizarán para comparar los resultados de los censos, acompañadas De proyecciones realizadas por otros métodos.

La descripción de este conjunto puede verse en el cuadro3,mientras el cuadro?? muestra la estructura típica del dataset.

11.3. Componente geográfico

Con el objetivo de enriquecer el dataset se incorpora una tabla con los polígonos geográficos de cada departamento. La misma se obtiene del Instituto Geográfico Nacional (IGM) [10], de donde se obtiene la capa SIG para todos los departamentos de la República Argentina. Luego se cruza con el listado de departamentos del AMBA , generando un dataset con las características geográficas sumadas a los datos censales recopilados desde 1991 a 2022.

En base

11.4. Herramientas

Para el guardado y manipulación de los datos se va a trabajar con un base de datos POSTGRES (Local). Se desarrollo justamente un proceso de ETL en Python y SQL mediante en primera crear todas las tablas necesarias, para luego producir la ingesta ,transformar en caso de que sea necesario, de los diferentes inputs que van a componer el modelo de datos.

12. Metodologías Aplicadas

..— TODAVIA SIN DESARROLLO.————

13. Análisis exploratorio de datos

13.1. Población

Con sustento en la base de datos .^MBA"(POSTGRES/POSTGIS) se analizarán los distintos datos recopilados según nivel de agregación. En primera instancia se generó un dataset con todos los departamentos del AMBA, sus características geográficas así como los valores de las variables correspondientes a los censos 1991-2001-2010-2022.1

En el cuadro 6 se puede observar el esquema del dataset .

Se observa en el cuadro 7 que existen valores nulos para el valor poblaciones, que se corresponden, con los casos de municipios de desaparecen en la reorganización administrativa desde 1991 a 2001.

A saber : Esteban Echeverría' , 'Ezeiza' , 'Florencio Varela' , 'Hurlingham' , 'Ituzaingó' , 'José C. Paz' , 'Malvinas Argentinas' , 'Morón' , 'San Miguel' y 'General Sarmiento' .

Se destaca también que para el censo 1991 no se detalla el total de viviendas particules y colectivas .

Cuadro 2: Dimensión Departamento

Codigo	Departamento	PartidoFrom	Codigo From	Sup1991	Sup2001	Comentarios
6028	Almirante Brown			122.0	122.0	
6035	Avellaneda			55.0	55.0	
6091	Berazategui			188.0	188.0	
6260	Esteban Echeverría			377.0	120.0	(1) Superficie modificada, cede tierras a Cañuelas y San Vicente y para la creación de Ezeiza y Presidente Perón. Leyes provinciales 11.550 del 20/10/1994 y 11.480 del 25/11/1993.
6270	Ezeiza	Esteban Echeverría	6260	0.0	223.0	(2) Se crea con tierras del partido de Esteban Echeverría. Ley provincial 11.550 del 20/10/1994.
6274	Florencio Varela			206.0	190.0	(3) Sup.modificada, cede tierras a Presidente Perón. Ley 11.480 del 25/11/1993.
6371	General San Martín			56.0	56.0	
6408	Hurlingham	Morón	6568	0.0	36.0	(4) Se crea con tierras del partido de Morón. Ley provincial 11.610 del 28/12/1994.
6410	Ituzaingó	Morón	6568	0.0	39.0	(5) Se crea con tierras del partido de Morón. Ley provincial 11.610 del 28/12/1994.
6412	José C. Paz	General Sarmiento	6005	0.0	50.0	(6) Se crea con tierras del partido de General Sarmiento. Ley provincial 11.551 del 20/10/1994.
6427	La Matanza			323.0	323.0	
6434	Lanús			45.0	45.0	
6490	Lomas de Zamora			89.0	89.0	
6515	Malvinas Argentinas	General Sarmiento	6005	0.0	63.0	(7) Se crea con tierras del partido de General Sarmiento e incorpora un sector del partido de Pilar. Ley provincial 11.551 del 20/10/1994.
6539	Merlo			170.0	170.0	
6560	Moreno			180.0	180.0	
6568	Morón			131.0	56.0	(8) Superficie modificada, cede tierras para la creación de los partidos de Hurlingham e Ituzaingó. Ley 11.610 del 28/12/1994.
6658	Quilmes			125.0	125.0	
6749	San Fernando			924.0	924.0	
6756	San Isidro			48.0	48.0	
6760	San Miguel	General Sarmiento	6005	0.0	80.0	(9) Se crea con tierras del partido de General Sarmiento. Ley provincial 11.551 del 20/10/1994.
6805	Tigre			360.0	360.0	
6840	Tres De Febrero			46.0	46.0	
6861	Vicente López			39.0	39.0	
6005	General Sarmiento			196.0	0.0	Desaparece para el año 2001

Column	Non-Null Count	Dtype
id	384 non-null	int64
CodigoDpto	384 non-null	object
ano	384 non-null	int64
Departamento	384 non-null	object
Poblacion	384 non-null	int64
Varones	384 non-null	int64
Mujeres	384 non-null	int64

Cuadro 3: Summary del dataset public.proyecciones




Figura 1: Población por departamento 1991-2022

id	CodigoDpto	ano	Departamento	Poblacion	Varones	Mujeres
1	6028	2010	Almirante Brown	557025	273352	283673
25	6028	2011	Almirante Brown	561349	275570	285779
49	6028	2012	Almirante Brown	565509	277794	287715
73	6028	2013	Almirante Brown	569911	279980	289931
97	6028	2014	Almirante Brown	574263	282143	292120
121	6028	2015	Almirante Brown	578513	284281	294232
145	6028	2016	Almirante Brown	582541	286295	296246
169	6028	2017	Almirante Brown	586564	288288	298276
193	6028	2018	Almirante Brown	590418	290157	300261
217	6028	2019	Almirante Brown	594270	292051	302219
.....						

Cuadro 4: Proyecciones del valor población por departamento Año 2010 a 2025 . Fuente INDEC

Asimismo se analiza la evolución de la densidad de población [hab/km²], la misma puede observarse en la figura 2. Las mismas consideraciones aplican en el caso de densidad respecto a los departamentos que sufren modificaciones administrativas entre 1991 y 2001, donde los valores de densidad se ven fuertemente afectados y no pueden asociarse al fenómeno poblacional.

13.1.1. Población. Vista geográfica

En este caso se busca una visualización geográfica del dataset. Utilizando el software QGIS conectado directamente a la base de datos AMBA (POSTGRES) se pudo disponer la información de cada Departamento con su geolocalización. Se detalla en la figura 3 la población total para cada departamento (Censos 1991 -2022). Se observa claramente que el distrito más poblado es La Matanza.

Cuadro 5: Descripción de Variables Geográficas

Variable	Nombre	Descripción
geom	geometry	Polígono WKT con los límites del departamento
fna	Nombre geográfico	Nombre completo que se utiliza para designar un objeto en un mapa o carta. Está formado por el término genérico y el término específico. Ejemplo: río Mendoza.
gna	Término genérico	Parte del nombre geográfico que indica el tipo de objeto que identifica. Ejemplo: río, monte, glaciar, establecimiento.
nam	Término específico	Parte de un nombre geográfico que acompaña al término genérico y que identifica e individualiza un objeto geográfico determinado. Ejemplo: Paraná en río Paraná; Upsala en glaciar Upsala; Las Marías en establecimiento Las Marías; Esperanza en el caso de bahía Esperanza.
in1	Código INDEC	Código único de vías de circulación asignado por el Instituto Nacional de Estadística y Censos de la República Argentina.
fdc	Fuente de captura	Identificación del nombre y tipo de fuente utilizada para capturar la información. Puede incluir fecha y otros datos adicionales.
sag	Autoridad de fuente	Nombre de la autoridad responsable de la información utilizada.




Figura 2: Densidad de Población por departamento 1991-2022

nam	cod_{depto}	anio	pob	var	muj	vivpart	vivtotal	sup	ind_{masc}	dens_{pob}
Almirante Brown	06028	1991	450698.0	222042.0	228656.0	nan	nan	157.87	97.1	2854.87
Almirante Brown	06028	2010	552902.0	270247.0	282655.0	156218.0	78.0	157.87	95.6	3502.26
Almirante Brown	06028	2022	585852.0	281842.0	301779.0	184403.0	60.0	157.87	93.4	3710.98
Almirante Brown	06028	2001	515556.0	252454.0	263102.0	143543.0	88.0	157.87	96.0	3265.70
Avellaneda	06035	2001	328980.0	155450.0	173530.0	117200.0	59.0	68.54	89.6	4799.82
Avellaneda	06035	1991	344991.0	164243.0	180748.0	nan	nan	68.54	90.9	5033.43
Avellaneda	06035	2010	342677.0	162264.0	180413.0	121307.0	68.0	68.54	89.9	4999.66
Avellaneda	06035	2022	370939.0	174572.0	194911.0	144988.0	64.0	68.54	89.6	5412.01
Berazategui	06091	2010	324244.0	158608.0	165636.0	96029.0	37.0	268.91	95.8	1205.77
Berazategui	06091	2022	360582.0	173892.0	186255.0	117699.0	37.0	268.91	93.4	1340.90
.....										

Cuadro 6: Dataset Censos AMBA

Cuadro 7: Summary de columnas de Censos AMBA

Column	Non-Null Count	Dtype
nam	96	object
cod_dept	96	object
anio	96	object
pob	90	float64
var	90	float64
muj	90	float64
vivpart	72	float64
vivtotal	72	float64
sup	96	object
ind_masc	90	object
dens_pob	90	object




Figura 3: Población Total Censos 1991 2022

13.1.2. Población - Ratios de crecimiento

En este caso se determinaron los ratios de crecimiento entre censos consecutivos para cada departamento. Para este análisis se trata de manera diferenciada aquellos municipios que han sufrido modificaciones administrativas desde 1991 a 2001, donde se que al desmembrarse en varios partidos, resignando superficie, algunas tasas o ratios de crecimiento se muestran negativos. Asimismo partidos que ha visto incrementada su superficie presentan tasas de crecimiento no representativas del fenómeno demográfico.

Por otra parte partidos que desaparecen o se crean en el año 2001 no se consideran el valor del ratio para el intervalo 1991-2001.

En el cuadro 8 se puede observar los valores obtenidos. Para el año en cuestión la tasa surge de dividir el valor poblacional del censo de este año sobre el valor poblacional del censo anterior, expresado en porcentaje.

Es decir:

$$\text{Growth Ratio} = \left(\frac{\text{Población}_{(\text{Censo } X)}}{\text{Población}_{(\text{Censo } X - 1)}} - 1 \right) \times 100 \quad (5)$$

nam	anio	pob	growth_ratio
Almirante Brown	2001	515556.0	14.39
Almirante Brown	2022	585852.0	5.96
Almirante Brown	2010	552902.0	7.24
Avellaneda	2001	328980.0	-4.64
Avellaneda	2010	342677.0	4.16
Avellaneda	2022	370939.0	8.25
Berazategui	2022	360582.0	11.21
Berazategui	2001	287913.0	17.55
Berazategui	2010	324244.0	12.62
Esteban Echeverría	2001	243974.0	-11.54
Esteban Echeverría	2010	300959.0	23.36
Esteban Echeverría	2022	339030.0	12.65
Ezeiza	2022	203283.0	24.16
Ezeiza	2010	163722.0	37.81
....			

Cuadro 8: Extracto. Tasa de crecimiento Intercensal

A partir de análisis estadístico simple sobre estas tasas se observa una gran disparidad en los valores, siendo que se trata de un sector geográfico de similares características demográficas. Cuadro 9

Estadístico	Valor
Count	66.000000
Mean	9.286961
Standard Deviation	13.111467
Minimum	-51.926259
25 % Percentile	3.033150
50 % Percentile	8.129835
75 % Percentile	16.476163
Maximum	41.466819

Cuadro 9: Summary Statistics for Growth Ratio

A partir de la elaboración de un gráfico boxplot se determinaron los **Outliers** para estas tasas de crecimiento.

En este caso en el cuadro 4 se observan 4 outliers , tanto en valores positivos como negativos. Como se comentó anteriormente no se analizarán los casos con modificaciones administrativas desde 1991 a 2001.Cuadro 2 .Se desestima el caso de Morón para el período 1991-2001 donde la tasa es negativa de 51.9, debido a la cesión de tierras para la




Figura 4: Box plot Tasas de crecimiento intercensa 1991-2022

creación de distintos partidos.

id	nam	codDept	anio	pob	growthRatio
54	Morón	06568	2001	309380.0	-51.92
78	Florencio Varela	06274	2001	348970.0	36.85
13	La Matanza	06427	2010	1775816.0	41.47
29	Ezeiza	06270	2010	163722.0	37.80

Cuadro 10: Outliers para Tasas de crecimiento intercensal

Se grafica a continuación (Figura 5) la curva población de los 3 outliers destacados :Florencio Varela ,La Matanza y Ezeiza.

13.1.3. Tasas de crecimiento intercensal.Coefficiente de Variación

Con el objetivo de profundizar el análisis de las tasas de crecimiento se procedió a calcular luego la desviación estandar y el coeficiente de variación por Departamento.

En primera instancia se agrupa por departamento para determinar la media y la desviación estándar de cada subset de datos. Se define el coeficiente de variación (CV) como:

$$CV_{(Departamento)} = \left(\frac{\text{Std.Dev}_{(Departamento)}}{\text{Mean}_{(Departamento)}} \right) \times 100 \quad (6)$$

El coeficiente de variación es una medida de la dispersión alrededor de la media de la población. En este caso sería curvas poblacionales con gran dispersión en su tasas de crecimiento para los censos del periodo analizado año 1991 -2022.-

En la figura 6 se observa el resultado .Se destaca en particular los valores extremos tanto negativos como positivos.A saber : Vincente López, Morón, Tres de Febrero, Avellaneda ,La Matanza , Esteban Echeverría, General San Martín. Cabe recordar en este instancia que los partidos de Esteban Echeverría , Florencio Varela y Morón sufrieron modificaciones administrativa en el período 1991-2001. En la figura 7 así como en la figura8 puede observarse la curvas

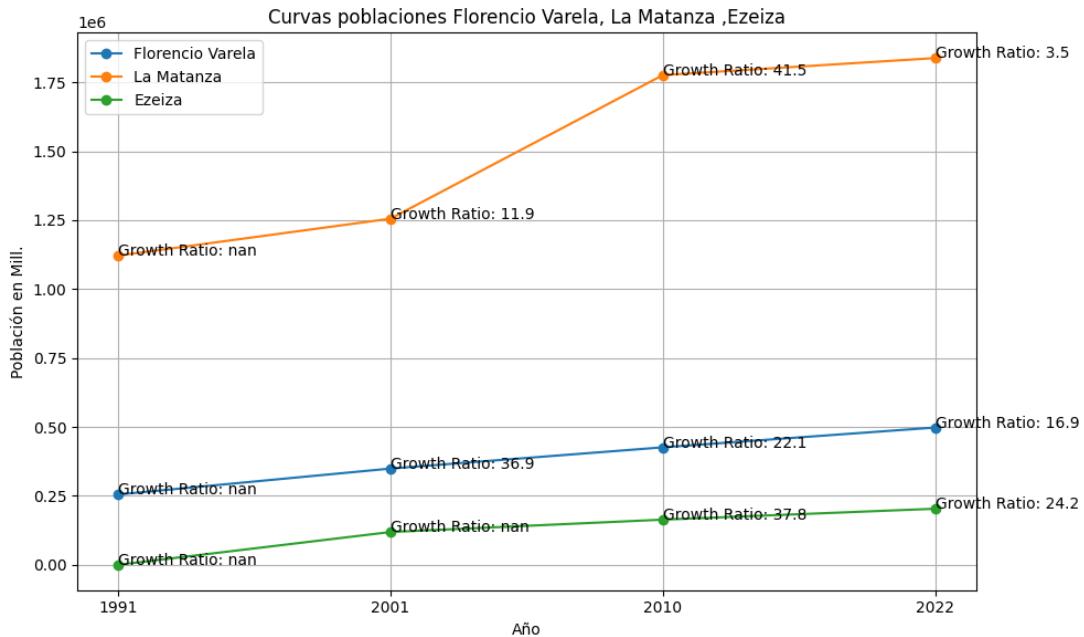


Figura 5: Curvas de Población por departamento 1991-2022

poblacionales de los departamentos destacados.

En estos casos se prestará particular atención a las predicciones hechas por el INDEC así como las metodologías que se implementen para la estimación de la curva poblacional, es esperable una mayor error de predicción en estos casos cuyas curvas presentan singularidades respecto a los municipios inmediatamente aledaños.

13.2. Densidad de Población

En el dataset se incorpora la densidad de población en habitantes/km², lógicamente estos valores se ven notablemente afectados por la reorganización político administrativa desde 1991 a 2001.

Si analizamos la distribución de los valores de densidad para cada censo, puede observarse distribuciones homogéneas simétricas, con un incremento en la mediana de cada población censal desde 2001 a 2022. El análisis univariado de esta variable puede observarse en la figura 9 y la figura 10.

13.2.1. Densidad de Población. Vista geográfica

Utilizando el software QGIS conectado directamente a la base de datos AMBA (POSTGRES) se pudo disponer la información de cada Departamento con su geolocalización. Si bien el distrito más poblado es La Matanza, debido a su extensión no es el departamento con mayor densidad poblacional en [hab/km²] figura 11, los distritos más densamente poblados son Lanús y Vicente López.




Figura 6: CV.Coefficiente de variación por departamento -1991-2022




Figura 7: Curvas poblacionales de alta dispersión - Población Media




Figura 8: Curvas poblacionales de alta dispersión - Población Alta




Figura 9: Densidad de Población. Análisis Univariado





Figura 10: Densidad de Población. Análisis Univariado

Figura 11: AMBA- Densidad [hab/km²] Censos 1991 2022

13.3. Tipo de Vivienda

A partir del censo 2001 se incorpora como atributo descriptivo en cada censo la composición o tipo de la vivienda, ya sea de tipo particular o colectiva. Se detalla en cada caso la cantidad de viviendas particulares('vivpart') en determinado departamento, así como la cantidad de viviendas colectivas presentes. Se presenta entonces la posibilidad de realizar un análisis univariado del porcentaje de viviendas particulares respecto al total de viviendas para un determinado departamento y año censal.

Se agrega al dataset una nueva columna definida como:

$$\text{VivPart \%} = \frac{\text{VivPart}}{\text{VivPart} + \text{VivColTot}} \times 100 \quad (7)$$

Surge de inmediato que mayoría de la población vive en viviendas particulares (mayor a 99.9%). Al analizar el comportamiento de este indicador se observa un leve incremento sostenido en el tiempo desde 1991 hasta 2022. Es decir que se observan cada vez más peso de las viviendas particulares. El análisis univariado de este indicador puede observarse en la figura 12 así como en la figura 13




Figura 12: Composición de viviendas. Análisis Univariado




Figura 13: Composición de viviendas. Análisis Univariado

13.4. Índice de Masculinidad

Un indicador habitual de las muestras poblacionales es el índice de masculinidad. Resultado de dividir el número de hombres entre el número de mujeres de una unidad geográfica o administrativa, generalmente multiplicado por 100 expresado como el número de hombres por cada 100 mujeres.

Es decir:

$$\text{IndMasc} = \frac{\text{Varones}}{\text{Mujeres}} \times 100 \quad (8)$$

Al analizar el comportamiento del índice a lo largo del tiempo se observa un descenso sostenido del mismo desde 1991 hasta 2022. Particularmente el máximo de la muestra presenta un descenso de 5 puntos porcentuales para el

año 2022, así como 2 puntos porcentuales la mediana.

Esto puede observarse en la figura14 así como en la figura15




Figura 14: Índice de Masculinidad. Análisis Univariado




Figura 15: Índice de Masculinidad. Análisis Univariado

14. ANEXO

14.1. Diccionario de Departamentos

Debido a las inconsistencias y falta de normalización de los archivos CSV que provee el INDEC, fue necesaria la creación de un diccionario de departamento asociando las distintas acepciones del nombre de departamento con su correspondiente código para que el proceso de ETL pudiese utilizar los códigos de departamento como clave foránea común a todos los Censos Nacionales. Se encontraron casos donde el mismo departamento figura nombrado con o sin tilde, con espacios o abreviaturas en el campo.

De esta forma en la ingesta (ETL) se buscaba el código de departamento correspondiente, que funciona como clave única. El formato del diccionario puede verse en el siguiente cuadro11.

14.2. Diagrama de entidad relación

14.2.1. Script Creación Tablas

```

1  -- ## POBLACION
2   CREATE TABLE IF NOT EXISTS public.poblacion (
3     Id SERIAL PRIMARY KEY,
4     "AnoCenso" VARCHAR(50),
5     "CodigoDpto" VARCHAR(50),
6     "Departamento" VARCHAR(150),

```

CodigoDpto	Departamento
6005	General Sarmiento
6005	General Sarmiento (4)
6260	Esteban Echeverría (1)
6260	Esteban Echeverría
6260	Esteban Echeverría
6270	Ezeiza
6270	Ezeiza (2)
6274	Florencio Varela (3)
6274	Florencio Varela
6274	Florencio Varela (3)

Cuadro 11: Diccionario. Primeras 10 filas




Figura 16: Diagrama de Entidad Relación

```

7   "Poblacion" INT,
8   "Varones" INT,
9   "Mujeres" INT,
10  "VivPartTot" INT,
11  "VivColectTot" INT,
12  "IndMasc" FLOAT,
13  "Superficie" INT,
14  "DensPob" FLOAT
15 );
16
17 TRUNCATE TABLE public.poblacion;
18
19 -- ## DIM Departamento
20 CREATE TABLE IF NOT EXISTS public.DimDepto (
21     Id SERIAL PRIMARY KEY,
22     "CodigoDpto" VARCHAR(50),

```

```

23      "Departamento" VARCHAR(150) ,
24      "PartidoFrom" VARCHAR(150) ,
25      "CodigoFrom" VARCHAR(50) ,
26      "Sup1991" INT ,
27      "Sup2001" INT ,
28      "IsAMBA" BOOLEAN ,
29      "Comentarios" VARCHAR(550)
30
31  );
32
33 TRUNCATE TABLE public.DimDepto;
34
35 --##DICCIONARIO DATOS PARTIDO CODIGO
36 CREATE TABLE IF NOT EXISTS public.diccionario (
37     "CodigoDpto" VARCHAR(50) ,
38     "Departamento" VARCHAR(150)
39 );
40
41 TRUNCATE TABLE public.diccionario;
42
43 --##PROYECCIONES
44 CREATE TABLE IF NOT EXISTS public.proyecciones (
45     Id SERIAL PRIMARY KEY,
46     "CodigoDpto" VARCHAR(50) ,
47     "ano" INT ,
48     "Departamento" VARCHAR(150) ,
49     "Poblacion" INT ,
50     "Varones" INT ,
51     "Mujeres" INT
52 );
53
54 TRUNCATE TABLE public.proyecciones;
55
56
57 ----- GEOMETRY TABLES ---
58 --1) departamento created from QGIS
59 --2) amba+censos
60
61
62 ---Now weed need to alter to add    Columns    para data de los censos
63
64 CREATE TABLE IF NOT EXISTS geo.amba_pob AS
65 SELECT *
66 FROM geo."vAMB0geom"
67 ALTER TABLE geo.amba_pob
68 ADD COLUMN pob1991 INT ,
69 ADD COLUMN pob2001 INT ,
70 ADD COLUMN pob2010 INT ,
71 ADD COLUMN pob2022 INT ;
72 ######
73 ALTER TABLE geo.amba_pob
74 ADD COLUMN dens1991 INT ,
75 ADD COLUMN dens2001 INT ,
76 ADD COLUMN dens2010 INT ,
77 ADD COLUMN dens2022 INT ;
78

```

```

79 UPDATE geo.amba_pob AS am
80 SET pob1991 = c.pob
81 FROM public.v_censos_amba c
82 WHERE am.cod_depto = c.cod_depto AND anio='1991';
83 --- Update Poblacion de los censos
84 UPDATE geo.amba_pob AS am
85 SET pob2001 = c.pob
86 FROM public.v_censos_amba c
87 WHERE am.cod_depto = c.cod_depto AND anio='2001';
88
89 UPDATE geo.amba_pob AS am
90 SET pob2010 = c.pob
91 FROM public.v_censos_amba c
92 WHERE am.cod_depto = c.cod_depto AND anio='2010';
93 UPDATE geo.amba_pob AS am
94 SET pob2022 = c.pob
95 FROM public.v_censos_amba c
96 WHERE am.cod_depto = c.cod_depto AND anio='2022';
97
98 --- Update DENSIDAD de los censos
99 UPDATE geo.amba_pob AS am
100 SET dens1991 = c.dens_pob
101 FROM public.v_censos_amba c
102 WHERE am.cod_depto = c.cod_depto AND anio='1991';
103 UPDATE geo.amba_pob AS am
104 SET dens2001 = c.dens_pob
105 FROM public.v_censos_amba c
106 WHERE am.cod_depto = c.cod_depto AND anio='2001';
107
108 UPDATE geo.amba_pob AS am
109 SET dens2010 = c.dens_pob
110 FROM public.v_censos_amba c
111 WHERE am.cod_depto = c.cod_depto AND anio='2010';
112 UPDATE geo.amba_pob AS am
113 SET dens2022 = c.dens_pob
114 FROM public.v_censos_amba c
115 WHERE am.cod_depto = c.cod_depto AND anio='2022';

```

Listing 1: CreateTables.sql

14.2.2. Script PopulateTables.sql

```

1      -- Step 1: Insert data from CSV file without the primary key column
2      --- POBLACION START ---
3      COPY public.poblacion ("AnoCenso", "CodigoDpto", "Departamento", "Poblacion"
4          , "Varones", "Mujeres", "VivPartTot", "VivColectTot", "IndMasc", "
5              Superficie","DensPob")
6      FROM 'C:/Temp/1991_A~1.CSV'
7      WITH (FORMAT csv, HEADER true, DELIMITER ';;', QUOTE '''', ESCAPE '',
8          ENCODING 'UTF8');

8
9      COPY public.poblacion ("AnoCenso", "CodigoDpto", "Departamento", "Poblacion"
10         , "Varones", "Mujeres", "VivPartTot", "VivColectTot", "IndMasc", "
11             Superficie","DensPob")
12     FROM 'C:/Temp/1991_Resto.CSV',

```

```

10    WITH (FORMAT csv, HEADER true, DELIMITER ';;', QUOTE ''', ESCAPE '''',
11          ENCODING 'UTF8');

12
13
14    COPY public.poblacion ("AnoCenso", "CodigoDpto", "Departamento", "Poblacion"
15        , "Varones", "Mujeres", "VivPartTot", "VivColectTot", "IndMasc", "
16        Superficie","DensPob")
17    FROM 'C:/Temp/2001.CSV'
18    WITH (FORMAT csv, HEADER true, DELIMITER ';;', QUOTE ''', ESCAPE '''',
19          ENCODING 'UTF8');

20
21
22    COPY public.poblacion ("AnoCenso", "CodigoDpto", "Departamento", "Poblacion"
23        , "Varones", "Mujeres", "VivPartTot", "VivColectTot", "IndMasc", "
24        Superficie","DensPob")
25    FROM 'C:/Temp/2010.CSV'
26    WITH (FORMAT csv, HEADER true, DELIMITER ';;', QUOTE ''', ESCAPE '''',
27          ENCODING 'UTF8');

28
29
30    COPY public.poblacion ("AnoCenso", "CodigoDpto", "Departamento", "Poblacion"
31        , "Varones", "Mujeres", "VivPartTot", "VivColectTot", "IndMasc", "
32        Superficie","DensPob")
33    FROM 'C:/Temp/2022.CSV'
34    WITH (FORMAT csv, HEADER true, DELIMITER ';;', QUOTE ''', ESCAPE '''',
35          ENCODING 'UTF8');

36
37
38    -- POBLACION END -----
39    ---- DICCIONARIO -----
40    COPY public.diccionario ("CodigoDpto", "Departamento")
41    FROM 'C:/Temp/DiccionarioPartidosCodigo.CSV'
42    WITH (FORMAT csv, HEADER true, DELIMITER ';;', QUOTE ''', ESCAPE '''',
43          ENCODING 'UTF8');

44
45
46    --- DIMdepto ---
47    COPY public.dimdepto (
48        "CodigoDpto",
49        "Departamento",
50        "PartidoFrom",
51        "CodigoFrom",
52        "Sup1991",
53        "Sup2001",
54        "IsAMBA",
55        "Comentarios")
56    FROM 'C:/Temp/DIM Departamento.CSV'
57    WITH (FORMAT csv, HEADER true, DELIMITER ';;', QUOTE ''', ESCAPE '''',
58          ENCODING 'UTF8');

59
60
61    --- Proyeccion 2025 ---
62    COPY public.proyecciones (
63        "CodigoDpto",
64        "ano",
65        "Departamento",
66        "Proyeccion2025");

```

```
54 "Poblacion",
55 "Varones",
56 "Mujeres")
57 FROM 'C:/Temp/proy_1025.CSV'
58 WITH (FORMAT csv, HEADER true, DELIMITER ';;', QUOTE '''', ESCAPE ''',
      ENCODING 'UTF8');
```

Listing 2: PopulateTables.sql